# *Workslop on the Rig Floor*: Evaluasi Verifikasi dan Penyaringan Klaim LLM Berbasis DDR untuk Mutu *Lessons Learned* NPT dalam Manajemen Pengetahuan Pengeboran

**Muhammad Reyvan Andrian[1], Muhammad Raju[2], Muhammad Arzaq Kafabih[3], Haikal Sulaeman Al Jabbar[4]**

[1]Institut Teknologi Bandung, Bandung, Indonesia
[2]Institut Teknologi Bandung, Bandung, Indonesia
[3]Institut Teknologi Bandung, Bandung, Indonesia
[4]Institut Teknologi Bandung, Bandung, Indonesia
**Corresponding author*: 12224096@mahasiswa.itb.ac.id; Tel.: +62 813-6692-9339

**Abstrak**

Laporan *lessons learned* yang disusun *large language model* (LLM) tampak rapi dan bersitasi, tetapi belum tentu didukung sumbernya. Penelitian ini menguji gerbang mutu yang menyaring klaim LLM terhadap *daily drilling report* (DDR) untuk kejadian *non-productive time* (NPT), dengan kriteria keberhasilan yang ditetapkan sebelum pengujian. Sebanyak 1.107 kejadian NPT dari 1.759 DDR lapangan Volve dibagi menurut keluarga sumur. Tiga kondisi dibandingkan: ekstraksi berbasis aturan (K1), LLM lokal bersitasi (K2), dan K2 yang disaring dengan cek leksikal serta AlignScore (K3). Dua penilai menilai 413 klaim dari 40 kejadian uji tanpa mengetahui kondisinya ($\kappa = 0{,}63$). Tidak satu pun dari empat kriteria tercapai. Proporsi klaim tidak didukung adalah 13,9% pada K1, 37,6% pada K2, dan 30,5% pada K3; reduksi relatif oleh gerbang hanya 18,8% dan tidak signifikan ($p = 0{,}059$), retensi kasus 65,0%, korelasi AlignScore dengan penilai 0,16, dan *precision at 5* turun dari 0,48 menjadi 0,37. Semua 40 laporan K2 memuat sedikitnya satu klaim tidak didukung. Analisis eksploratif menunjukkan bahwa gerbang membuang 25 dari 29 galat isi atau keluaran rusak, tetapi kedua jenis itu hanya seperempat dari 117 galat; sisanya berupa salah peran, omisi, dan pelajaran berasumsi yang tidak terjangkau pencocokan klaim dengan sumber. Hanya 23 dari 100 narasi NPT yang diaudit menyebut penyebab secara eksplisit. Besar selisih K2 terhadap K1 bergantung pada penilai. Hasil ini menunjukkan bahwa sitasi dan metrik otomatis belum dapat menggantikan tinjauan ahli, mutu basis kasus sudah dibatasi sejak DDR ditulis, dan protokol evaluasinya dapat menjadi uji terima sebelum LLM dipakai dalam manajemen pengetahuan pengeboran.

***Kata kunci:*** *daily drilling report, large language model, manajemen pengetahuan, non-productive time, verifikasi klaim*

***Abstract***

*Lessons learned drafted by a large language model (LLM) look polished and cited, yet may not be supported by their sources. This study tests a quality gate that filters LLM claims against daily drilling reports (DDRs) for non-productive time (NPT) events, with success criteria fixed before testing. In total, 1,107 NPT events from 1,759 Volve DDRs were split by well family. Three conditions were compared: rule-based extraction (K1), a local LLM with mandatory citations (K2), and K2 filtered by a lexical check and AlignScore (K3). Two raters, blind to condition, judged 413 claims from 40 test events ($\kappa = 0.63$). None of the four criteria was met. Unsupported claims averaged 13.9% for K1, 37.6% for K2, and 30.5% for K3; the relative reduction was only 18.8% and not significant ($p = 0.059$), case retention was 65.0%, the AlignScore–rater correlation was 0.16, and precision at 5 fell from 0.48 to 0.37. All 40 K2 reports contained at least one unsupported claim. Exploratory analysis shows that the gate removed 25 of 29 content or malformed-output errors, but these were only a quarter of 117 errors; the rest were role errors, omissions, and assumption-laden lessons that claim-to-source matching cannot reach. Only 23 of 100 audited NPT narratives state the cause explicitly. The K2–K1 gap depended on the rater. Citations and automatic metrics cannot yet replace expert review, case-base quality is limited when DDRs are written, and the evaluation protocol can serve as an acceptance test before LLMs enter drilling knowledge management.*

***Keywords:*** *claim verification, daily drilling report, knowledge management, large language model, non-productive time*

## 1. PENDAHULUAN

*Lifting* minyak nasional masih berada di bawah target. Hingga akhir Mei 2026, realisasi *lifting* minyak tercatat sekitar 570 ribu barel per hari, sedangkan target Anggaran Pendapatan dan Belanja Negara (APBN) 2026 sebesar 610 ribu barel per hari [1]. Upaya menutup selisih tersebut bertumpu pada kegiatan pengeboran, antara lain melalui rencana Pertamina Hulu Energi mengebor sekitar 800 sumur eksploitasi pada 2026 [2]. Dengan jumlah sumur sebesar itu, efisiensi setiap operasi pengeboran berpengaruh langsung terhadap biaya dan waktu yang diperlukan untuk menghasilkan produksi.

Salah satu sumber inefisiensi utama dalam pengeboran ialah waktu nonproduktif atau *non-productive time* (NPT), yaitu waktu operasi yang hilang akibat kejadian tidak terencana, seperti kerusakan peralatan, hilang sirkulasi (*lost circulation*), dan pipa terjepit (*stuck pipe*). Dari sisi operator, NPT dilaporkan mencapai sekitar

20% dari total waktu konstruksi sumur [3]. Kondisi serupa terjadi di Indonesia. Pada 50 sumur di satu lapangan, NPT mencakup sekitar 4.055 dari 21.318 jam operasi atau kurang lebih 19%, dan hilang sirkulasi menyumbang 76,8% NPT pada trayek lubang 8½ inci (216 mm) [4]. Dominasi satu jenis gangguan pada trayek tertentu mengisyaratkan bahwa sebagian NPT bersifat berulang sehingga berpeluang ditekan apabila pengalaman dari sumur-sumur sebelumnya dimanfaatkan secara sistematis.

Pemanfaatan pengalaman tersebut merupakan persoalan manajemen pengetahuan. Gangguan beserta penanganannya direkam dalam laporan harian pengeboran atau *daily drilling report* (DDR). Rekaman ini menjadi bahan bagi sistem *lessons learned*, yaitu sistem yang menangkap, menyimpan, dan menyalurkan pelajaran dari pengalaman kepada pengguna yang membutuhkannya [5]. Salah satu pendekatan yang banyak dikaji untuk sistem tersebut ialah penalaran berbasis kasus (*case-based reasoning*, CBR), yang menyelesaikan masalah baru dengan menelusuri dan menyesuaikan solusi dari kasus serupa di masa lalu [6]. CBR telah diterapkan secara luas dalam rekayasa pengeboran [7], termasuk pada sistem pendukung keputusan waktu nyata untuk operasi sumur berbiaya tinggi [8]. Namun, keberadaan sistem tidak dengan sendirinya menjamin terjadinya pembelajaran. Industri migas dinilai belum belajar secara efektif dari proyeknya sendiri karena adanya hambatan kognitif dan sosial [9]. Pada CBR, persoalan ini juga berkaitan langsung dengan mutu basis kasus karena kasus yang tersimpan akan ditemukan kembali dan dipakai ulang sebagai rujukan keputusan [6]. Dengan demikian, mutu pengetahuan yang tersimpan menentukan mutu rekomendasi yang dihasilkan.

Persoalan mutu tersebut berawal dari sifat DDR itu sendiri. Narasi DDR yang ditulis oleh personel pengeboran memuat banyak simbol teknis, istilah yang disingkat atau salah eja, serta kalimat yang tidak lengkap [10]. Pengolahan ribuan laporan semacam ini secara manual memerlukan waktu yang lama dan keahlian khusus sehingga otomatisasi menjadi kebutuhan. Model bahasa besar atau *large language model* (LLM) mulai dimanfaatkan untuk kebutuhan tersebut. Di industri migas, penerapan model berskala besar masih berada pada tahap awal, dan kuantitas serta mutu data menjadi salah satu kendalanya [11]. Meskipun demikian, LLM telah digunakan untuk mengidentifikasi aktivitas rig, menetapkan kode aktivitas, mengategorikan NPT, dan menyusun ringkasan kejadian lubang bor dari DDR [12]. Studi lain memanfaatkan LLM sebagai agen yang menjawab pertanyaan operasional dari data sumur yang heterogen, termasuk DDR lapangan Volve [13].

Pemanfaatan LLM membawa risiko tersendiri. LLM dapat menghasilkan teks yang lancar dan meyakinkan, tetapi tidak setia pada sumbernya; gejala ini dikenal sebagai halusinasi [14], [15]. Pada uji peringkasan dokumen pendek, proporsi ringkasan yang mengandung halusinasi berkisar 1,8–24,2% antarmodel [16]. Kewajiban menyertakan sitasi juga belum menjamin kebenaran. Evaluasi terhadap mesin pencari generatif menunjukkan bahwa hanya 51,5% kalimat yang didukung penuh oleh sitasinya dan hanya 74,5% sitasi yang benar-benar mendukung kalimat yang dirujuknya [17]. Di lingkungan kerja, keluaran kecerdasan artifisial (*artificial intelligence*, AI) yang tampak rapi, tetapi tidak cukup bersubstansi untuk memajukan pekerjaan disebut *workslop* [18], [19]. Keluaran semacam ini memindahkan beban pemeriksaan kepada penerimanya. Eksperimen lapangan pada konsultan bahkan menunjukkan bahwa untuk tugas di luar jangkauan kemampuan AI, pengguna AI sekitar 19 poin persentase lebih jarang menghasilkan jawaban yang benar dibandingkan dengan kelompok kontrol [20]. Dari sudut pandang manajemen pengetahuan, halusinasi menggerus akurasi pengetahuan dan kredibilitas institusi yang mengelolanya [21]. Dalam basis kasus, dampaknya dapat berlipat: satu klaim tanpa dasar, misalnya penyebab gangguan yang tidak pernah dicatat dalam DDR, dapat ditemukan kembali dan memengaruhi setiap rekomendasi yang memakainya.

Sejumlah pendekatan telah dikembangkan untuk menekan risiko tersebut. LLM dapat diwajibkan menyertakan sitasi pada setiap pernyataan [22]. Keluaran yang panjang dapat diurai menjadi fakta atomik, lalu setiap fakta diverifikasi terhadap sumber [23]. Keterdukungan pernyataan oleh sumber dapat dinilai oleh manusia menggunakan kerangka atribusi yang baku [24]. Selain itu, model konsistensi fakta, seperti AlignScore [25] dan *Hughes Hallucination Evaluation Model* (HHEM) [26], dapat menilai keselarasan teks dengan sumbernya secara otomatis. Meskipun demikian, pendekatan tersebut umumnya dikembangkan dan diuji pada teks umum, seperti berita, ensiklopedia, dan biografi. Kajian komparatif juga menunjukkan bahwa tidak ada satu metrik faktualitas pun yang unggul pada semua kondisi dan jenis kesalahan [27]. Oleh karena itu, kinerja detektor otomatis pada teks operasional yang padat singkatan, seperti DDR, tidak dapat diasumsikan begitu saja dan perlu divalidasi dengan penilaian manusia.

Berdasarkan uraian tersebut, terdapat tiga celah penelitian. Pertama, penelitian LLM pada DDR masih berfokus pada klasifikasi, ekstraksi, dan tanya jawab [12], [13], sedangkan skor kesesuaian dengan sumber yang telah diusulkan pada DDR [13] belum divalidasi dengan penilaian manusia; penulisnya sendiri menempatkan validasi oleh ahli sebagai pekerjaan lanjutan. Kedua, sepengetahuan penulis, belum ada penelitian pada laporan operasi pengeboran yang memisahkan nilai tambah penyaringan klaim dari sekadar kewajiban sitasi, padahal sitasi saja terbukti belum memadai [17]. Ketiga, dampak penyaringan klaim terhadap kegunaan basis pengetahuan, yaitu jumlah kasus yang tetap layak pakai dan ketepatan penelusuran kasus serupa, belum diukur.

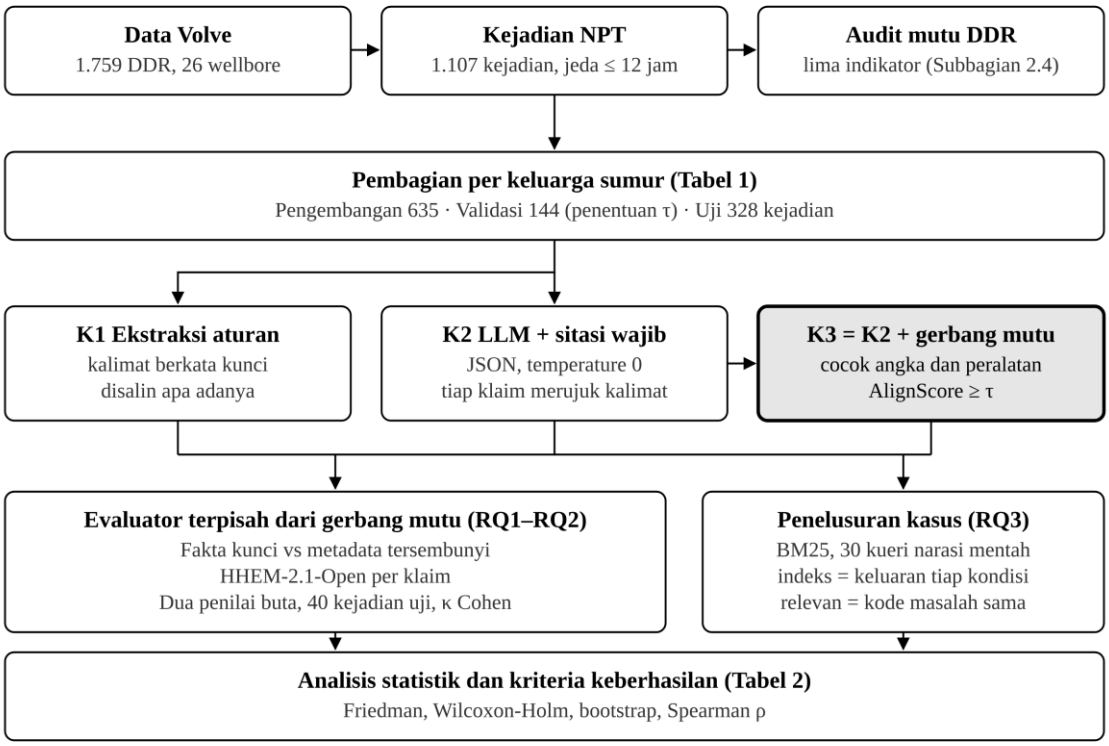
Untuk mengisi celah tersebut, penelitian ini memberikan tiga kontribusi. Pertama, penyaringan klaim berbasis sumber diterapkan sebagai gerbang mutu (*quality gate*) di atas LLM dengan sitasi wajib sehingga pengaruhnya dapat diukur secara terpisah pada keluaran yang sama. Kedua, penelitian ini menyajikan protokol evaluasi yang kriteria keberhasilannya ditetapkan sebelum pengujian dan yang memakai tiga alat ukur terpisah dari mekanisme penyaringan, yaitu metadata yang disembunyikan dari LLM sebagai kunci jawaban, detektor

halusinasi yang berbeda, dan penilaian buta oleh dua penilai manusia. Ketiga, mutu pengetahuan diukur hingga dampaknya pada fungsi manajemen pengetahuan, yaitu retensi kasus layak pakai dan ketepatan penelusuran kasus. Seluruh hasil dilaporkan terhadap kriteria tersebut, termasuk kriteria yang tidak tercapai, dan dilengkapi dengan analisis jenis galat untuk menjelaskannya. Selain itu, mutu informasi dalam DDR diaudit sebelum LLM digunakan sehingga batas atas pengetahuan yang dapat diekstraksi dari sumber dapat diketahui.

Penelitian ini bertujuan menguji penyaringan klaim berbasis sumber untuk menjaga mutu basis kasus NPT yang disusun dari DDR dengan bantuan LLM. Pengujian menggunakan data terbuka lapangan Volve [28]. Pertanyaan penelitian yang diajukan ialah (1) seberapa sering *lessons learned* hasil LLM memuat klaim yang tidak didukung DDR, (2) apakah penyaringan klaim menurunkan klaim tersebut sambil mempertahankan kasus layak pakai dan fakta penting, serta (3) apakah penyaringan meningkatkan kecocokan kategori masalah pada penelusuran kasus serupa. Ketiga pertanyaan tersebut dijawab terhadap kriteria keberhasilan yang ditetapkan sebelum pengujian sehingga hasil yang tidak sesuai harapan tetap dilaporkan beserta analisis penyebabnya. Dengan cara ini, protokol evaluasinya sekaligus diuji sebagai uji terima sebelum LLM dipakai untuk mengisi basis kasus pengeboran.

## 2. METODE

Penelitian dilaksanakan dalam enam tahap, yaitu penyiapan data, audit mutu pengetahuan DDR, pembagian data, pembangkitan *lessons learned* dalam tiga kondisi, penyaringan klaim, serta evaluasi dan analisis statistik. Alur penelitian ditunjukkan pada Gambar 1.




**Gambar 1.** Alur penelitian. K3 tidak membangkitkan teks baru, tetapi menyaring keluaran K2.

### 2.1 Desain Penelitian

Penelitian ini menggunakan desain eksperimen komparatif berpasangan. Setiap kejadian NPT pada data uji diproses oleh ketiga kondisi sehingga perbandingan dilakukan pada kejadian yang sama dan pengaruh variasi antarkejadian dapat dikendalikan. Kriteria keberhasilan ditetapkan sebelum pengujian dan dirangkum pada Subbagian 2.10 agar keputusan atas hasil tidak bergantung pada angka yang diperoleh.

### 2.2 Data Penelitian

Data penelitian ialah DDR dari set data terbuka lapangan Volve yang dirilis Equinor di bawah *Equinor Open Data Licence* [28]. Lisensi tersebut mengizinkan penggunaan data untuk penelitian dengan mencantumkan atribusi kepada pemilik data. Set data memuat 1.759 DDR berformat *Wellsite Information Transfer Standard Markup Language* (WITSML) versi 1.4 dari 26 lubang sumur (*wellbore*), dengan 23.447 entri aktivitas dan total durasi 39.398 jam. Setiap entri aktivitas memuat waktu mulai dan selesai, kode aktivitas (*proprietaryCode*), status (*state* dan *stateDetailActivity*), serta narasi bebas (*comments*). Setiap DDR juga memuat ringkasan 24 jam (*sum24Hr*) yang ditulis personel pengeboran. Data ini tidak memuat informasi pribadi.

### 2.3 Definisi Kejadian NPT

Suatu aktivitas dikategorikan sebagai NPT apabila memenuhi sedikitnya satu kondisi berikut: kodenya diawali *interruption*, statusnya *fail*, atau *stateDetailActivity* bernilai selain *success*. Aktivitas NPT pada lubang sumur yang sama dengan kode yang sama dan jeda antaraktivitas paling lama 12 jam digabung menjadi satu kejadian. Kejadian dipilih sebagai satuan analisis karena satu gangguan sering tercatat sebagai beberapa entri aktivitas, bahkan lintas hari. Prosedur ini menghasilkan 1.107 kejadian NPT dengan total durasi 9.626,5 jam. Jenis masalah setiap kejadian ditentukan dari kode aktivitasnya, misalnya *repair*, *fish*, atau *lost circulation*, atau dari nilai *stateDetailActivity* apabila kodenya tidak spesifik. Kode *other* diperlakukan sebagai label yang tidak spesifik.

### 2.4 Audit Mutu Pengetahuan

Sebelum LLM digunakan, mutu informasi dalam DDR diaudit dengan lima indikator. Pertama, proporsi waktu interupsi, yaitu jam aktivitas berkode *interruption* terhadap total jam aktivitas. Kedua, proporsi kode tidak spesifik, yaitu jam berkode *interruption – other* terhadap seluruh jam interupsi. Ketiga, penyebutan penyebab, yaitu kejadian yang narasinya memuat penanda kausal, seperti *due to*, *caused by*, *because*, *as a result*, *suspected*, *probably*, dan *indicated*. Keempat, penyebutan dalam ringkasan harian, yaitu hari dengan sedikitnya 2 jam NPT berjenis spesifik yang ringkasan 24 jamnya menyebut jenis tersebut. Kelima, kasus layak pakai, yaitu kejadian yang memiliki label jenis masalah spesifik dan narasinya memuat sedikitnya satu kata tindakan. Selain itu, kejadian langka didefinisikan sebagai kejadian berjenis *fish* atau *stuck pipe*, hilang sirkulasi, *sidetrack*, dan *well control*.

Indikator ketiga hingga kelima bergantung pada kamus kata kunci. Oleh karena itu, ketiganya divalidasi pada 100 kejadian yang dipilih secara acak dan dinilai secara manual oleh kedua penilai klaim (Subbagian 2.8) secara terpisah tanpa melihat hasil aturan. Presisi, *recall*, dan koefisien kappa Cohen [29] dilaporkan untuk setiap indikator.

### 2.5 Pembagian Data

Kejadian dibagi menjadi data pengembangan, validasi, dan uji berdasarkan keluarga sumur, yaitu sumur induk beserta seluruh lubang cabangnya (*sidetrack*). Pembagian per keluarga mencegah kebocoran informasi karena lubang cabang berbagi bagian atas sumur dan memiliki narasi yang mirip dengan sumur induknya. Keluarga 15/9-19 ditempatkan pada data pengembangan karena memuat 57 dari 79 kejadian langka. Penempatan ini memastikan kueri kejadian langka dari data uji memiliki kasus pembanding pada indeks. Konsekuensinya, data uji hanya memuat 12 kejadian langka sehingga hasil untuk kejadian langka dilaporkan secara deskriptif. Komposisi pembagian data disajikan pada Tabel 1.

**Tabel 1.** Pembagian data berdasarkan keluarga sumur

| Bagian | Keluarga sumur | Kejadian | Kejadian langka | Kejadian ≥ 6 jam | Kegunaan |
|---|---|---|---|---|---|
| Pengembangan | 15/9-19, F-1, F-10, F-12, F-14 | 635 (57,4%) | 65 | 189 | Indeks kasus, kamus entitas |
| Validasi | F-11, F-7 | 144 (13,0%) | 2 | 51 | Penentuan $\tau$ |
| Uji | F-15, F-4, F-5, F-9 | 328 (29,6%) | 12 | 103 | Perbandingan kondisi |
| **Total** | **11 keluarga** | **1.107 (100%)** | **79** | **343** | |

Sumber: diolah dari data Volve [28].

### 2.6 Kondisi Pembangkitan *Lessons Learned*

Narasi setiap kejadian disegmentasi menjadi kalimat bernomor (S1, S2, dan seterusnya) dengan aturan pemenggalan yang mempertahankan singkatan teknis. LLM hanya menerima narasi tersebut, sedangkan kode masalah, status kegagalan, kedalaman, dan durasi disembunyikan untuk digunakan sebagai kunci jawaban. Narasi asli berbahasa Inggris sehingga masukan dan keluaran LLM juga berbahasa Inggris untuk menghindari kesalahan penerjemahan. Tiga kondisi yang dibandingkan adalah sebagai berikut.

**K1, ekstraksi berbasis aturan.** Kalimat yang memuat kata kunci masalah atau tindakan dari kamus audit disalin apa adanya sebagai klaim, maksimal enam kalimat pertama per kejadian. K1 menjadi pembanding tanpa model bahasa: klaimnya selalu bersumber dari DDR, tetapi tidak disintesis menjadi pelajaran.

**K2, LLM dengan sitasi wajib.** LLM Qwen2.5-7B-Instruct yang dijalankan secara lokal (Subbagian 2.11) dengan *temperature* 0 diminta menyusun *lessons learned* dalam format JSON yang terdiri atas lima bagian, yaitu masalah, penyebab, tindakan, hasil, dan pelajaran. Instruksi model membatasi keluaran hanya pada kalimat bernomor yang diberikan serta melarang model memakai pengetahuan di luar narasi, menebak, ataupun

menambahkan angka, peralatan, penyebab, dan durasi yang tidak tertulis. Setiap butir pada empat bagian pertama merupakan satu klaim fakta yang wajib menyebutkan nomor kalimat sumbernya, mengikuti prinsip pembangkitan teks bersitasi [22]. Jumlah butir dibatasi, yaitu 1–3 masalah, 0–3 penyebab, 1–5 tindakan, 0–3 hasil, dan 1–2 pelajaran. Jawaban "tidak diketahui" (ditulis "unknown" pada keluaran berbahasa Inggris) diperbolehkan apabila informasi tidak tersedia dalam narasi. Butir pelajaran berupa rekomendasi wajib merujuk butir fakta yang mendasarinya. LLM juga mengisi tiga fakta kunci, yaitu kategori masalah dari delapan pilihan, keterlibatan kegagalan peralatan, dan kedalaman kejadian.

**K3, LLM dengan gerbang mutu.** Keluaran K2 yang sama disaring oleh gerbang mutu (Subbagian 2.7). Karena K3 tidak membangkitkan teks baru, selisih hasil antara K2 dan K3 mencerminkan pengaruh penyaringan semata.

### 2.7 Gerbang Mutu

Setiap klaim fakta K2 diperiksa dalam dua langkah. Langkah pertama ialah pemeriksaan leksikal: seluruh angka dan seluruh nama peralatan dalam klaim harus terdapat pada kalimat sumber yang dirujuk. Nama peralatan dikenali menggunakan kamus entitas yang disusun dari data pengembangan, misalnya *top drive*, *mud pump*, dan *blowout preventer*. Langkah kedua ialah perhitungan skor keselarasan antara klaim dan gabungan kalimat sumber yang dirujuknya menggunakan AlignScore [25] dengan *checkpoint* base. Keputusan gerbang mutu untuk klaim $c$ dirumuskan pada Persamaan (1).

$$g(c) = L(c) \cdot I(s(c) \geq \tau) \tag{1}$$

dengan $g(c)$ bernilai 1 apabila klaim lolos, $L(c)$ bernilai 1 apabila klaim lolos pemeriksaan leksikal, $s(c)$ ialah skor AlignScore, $\tau$ ialah ambang penerimaan, dan $I(\cdot)$ ialah fungsi indikator. Klaim tanpa rujukan kalimat otomatis tidak lolos, sedangkan klaim "tidak diketahui" diteruskan karena tidak memuat fakta; konsekuensinya, gerbang mutu tidak dapat mendeteksi jawaban "tidak diketahui" yang keliru. Gerbang mutu hanya membuang klaim dan tidak menulis ulang klaim yang tersisa. Butir pelajaran lolos hanya apabila seluruh butir fakta yang dirujuknya lolos dan butir tersebut tidak memuat angka atau nama peralatan baru.

Ambang $\tau$ ditentukan pada data validasi. Sebanyak 15 kejadian validasi yang memuat sedikitnya dua kalimat dipilih secara acak dan dilabeli secara manual oleh dua penulis yang menyusun gerbang mutu, lalu dipilih nilai $\tau$ pada kisi 0,05–0,95 yang memaksimalkan skor F1 dalam mendeteksi klaim yang tidak didukung. Dari 53 klaim fakta yang dilabeli, diperoleh ambang 0,94, yang dibekukan sebelum data uji dinilai. Sampel validasi ini hanya memuat delapan klaim tidak didukung; ketidakpastian yang ditimbulkannya dilaporkan pada Subbagian 3.1. Klaim yang tidak lolos ditahan dari indeks penelusuran kasus, sedangkan narasi sumbernya tetap tersimpan sehingga dapat ditinjau ulang.

### 2.8 Evaluasi Mutu Klaim

Evaluasi menggunakan tiga alat ukur yang terpisah dari gerbang mutu agar mekanisme penyaringan tidak menilai dirinya sendiri.

**Ketepatan fakta kunci.** Tiga fakta kunci, yaitu jenis masalah, keterlibatan kegagalan peralatan, dan kedalaman kejadian, dibandingkan dengan metadata yang disembunyikan. Kedalaman dinilai benar apabila selisihnya tidak lebih dari 5% atau 10 m. Jawaban "tidak diketahui" dinilai benar apabila informasi tersebut memang tidak terdapat dalam narasi.

**Skor HHEM.** Setiap klaim dinilai dengan HHEM-2.1-Open [26] terhadap kalimat sumber yang dirujuknya. Klaim dengan skor kurang dari 0,5 dianggap tidak konsisten dengan sumber.

**Penilaian manusia.** Sebanyak 40 kejadian uji dipilih secara berstrata, terdiri atas 10 kejadian langka, 15 kejadian berdurasi sedikitnya 6 jam, dan 15 kejadian acak lainnya. Penilaian dilakukan oleh dua penulis yang berlatar belakang mahasiswa Program Studi Teknik Perminyakan, Institut Teknologi Bandung (ITB). Latar belakang ini membantu penilai memahami istilah dan singkatan teknis dalam DDR. Untuk mengurangi bias, peran penulis dipisahkan: dua penulis lain menyusun instruksi model K2 (Subbagian 2.6), merancang gerbang mutu, dan menetapkan ambang $\tau$, sedangkan kedua penilai tidak terlibat dalam tahap tersebut serta tidak melihat keluaran LLM secara utuh, skor, label kondisi, maupun hasil penyaringan sebelum penilaian selesai. Klaim unik dari K1 dan K2 untuk setiap kejadian disajikan dalam urutan acak tanpa label kondisi. Karena klaim K3 merupakan bagian dari klaim K2, label klaim K3 diambil dari label klaim K2 yang lolos gerbang mutu sehingga penilai tidak mengetahui klaim mana yang lolos. Lembar penilaian memuat 413 klaim unik yang mewakili 472 pasangan klaim–kondisi, yaitu 153 dari K1 dan 319 dari K2.

Setiap klaim dinilai terhadap seluruh narasi kejadian dengan tiga kategori, yaitu didukung, didukung sebagian, dan tidak didukung, mengikuti kerangka atribusi Rashkin dkk. [24]. Kriteria setiap kategori untuk setiap bagian klaim dituangkan dalam matriks penilaian yang disusun sebelum anotasi. Menurut matriks tersebut, klaim berlabel tidak didukung apabila unsur intinya tidak sesuai dengan narasi atau dengan bagian tempat klaim itu berada, misalnya tindakan rutin yang ditulis sebagai masalah, dan penilai memilih label yang lebih ketat apabila ragu. Butir pelajaran dinilai didukung apabila dapat diturunkan dari fakta yang didukung tanpa menambahkan fakta baru. Sebelum penilaian, kedua penilai melakukan kalibrasi pada lima kejadian validasi (41 klaim), lalu matriks penilaian dibekukan. Selanjutnya, kedua penilai bekerja secara terpisah tanpa berdiskusi

(Lampiran, Gambar L1 dan L2), dan label sebelum diskusi disimpan untuk menghitung kesepakatan. Sebanyak 101 klaim yang labelnya berbeda dibahas bersama oleh kedua penilai dengan merujuk kembali ke narasi sumber dan matriks penilaian hingga disepakati satu label akhir; kondisi asal klaim tetap tersembunyi selama diskusi. Karena penilai merupakan bagian dari tim penulis dan keluaran K1 berupa kutipan langsung yang lebih mudah dikenali, potensi bias penilaian dibahas sebagai keterbatasan pada Bagian 3.

Proporsi klaim tidak didukung pada kondisi $k$ untuk kejadian $e$ dihitung dengan Persamaan (2), sedangkan penurunan relatif proporsi tersebut dari K2 ke K3 dihitung dengan Persamaan (3).

$$U_{k,e} = \frac{n^{\mathrm{td}}_{k,e}}{n_{k,e}} \tag{2}$$

$$R = \frac{\overline{U}_{\mathrm{K2}} - \overline{U}_{\mathrm{K3}}}{\overline{U}_{\mathrm{K2}}} \times 100\% \tag{3}$$

dengan $n_{k,e}$ ialah jumlah klaim, $n^{\mathrm{td}}{}_{k,e}$ ialah jumlah klaim yang dinilai tidak didukung atau hanya didukung sebagian, dan $\bar{U}_k$ ialah rerata $U_{k,e}$ pada seluruh kejadian. Retensi kasus layak pakai dihitung dengan Persamaan (4). Suatu kasus dinyatakan tetap layak apabila keluaran K3 masih memuat sedikitnya satu klaim masalah dan satu klaim tindakan yang lolos.

$$Ret = \frac{|C_{\mathrm{tetap}}|}{|C_{\mathrm{layak}}|} \times 100\% \tag{4}$$

dengan $C_{\mathrm{layak}}$ ialah himpunan kejadian uji yang layak pakai di sumber dan $C_{\mathrm{tetap}}$ ialah anggota $C_{\mathrm{layak}}$ yang tetap layak setelah penyaringan. Retensi dihitung secara otomatis pada seluruh kasus layak pakai di data uji, bukan hanya pada 40 kejadian yang dinilai penilai.

Kesepakatan antarpenilai dihitung dengan koefisien kappa Cohen [29] menggunakan Persamaan (5) pada label biner, yaitu didukung penuh atau tidak, sebelum ketidaksepakatan diselesaikan melalui diskusi. Nilai $\kappa$ ditafsirkan menurut kategori Landis dan Koch [30].

$$\kappa = \frac{p_o - p_e}{1 - p_e} \tag{5}$$

dengan $p_{\mathrm{o}}$ ialah proporsi kesepakatan teramati dan $p_{\mathrm{e}}$ ialah proporsi kesepakatan yang diharapkan secara kebetulan.

### 2.9 Penelusuran Kasus

Pengaruh penyaringan terhadap fungsi basis pengetahuan diukur melalui penelusuran kasus. Untuk setiap kondisi, keluaran kejadian pada data pengembangan diindeks menggunakan BM25 [31] dengan parameter baku $k_1 = 1{,}2$ dan $b = 0{,}75$. Kueri berupa narasi mentah dari 30 kejadian uji sehingga kueri identik untuk ketiga kondisi dan perbedaan hasil hanya berasal dari isi indeks. Kueri dipilih secara berstrata dari jenis masalah spesifik yang memiliki sedikitnya lima kasus pada indeks. Kejadian berkode *other* dikeluarkan karena kode tersebut tidak menunjukkan jenis masalah yang sama. Suatu hasil dinilai relevan apabila kode masalah spesifiknya sama dengan kode kueri. Kinerja penelusuran diukur dengan *precision*@5 [32] menggunakan Persamaan (6).

$$P@5 = \frac{1}{|Q|} \sum_{q \in Q} \frac{\mathrm{rel}_q(5)}{5} \tag{6}$$

dengan $Q$ ialah himpunan kueri dan $\mathrm{rel}_q(5)$ ialah jumlah hasil relevan pada lima peringkat teratas untuk kueri $q$. Karena K1 berupa kutipan narasi, K1 diuntungkan secara leksikal terhadap kueri narasi mentah. Oleh karena itu, perbandingan utama untuk pertanyaan penelitian ketiga ialah K3 terhadap K2.

### 2.10 Analisis Statistik dan Kriteria Keberhasilan

Perbandingan ketiga kondisi pada tingkat kejadian dilakukan dengan uji Friedman [33] karena data bersifat berpasangan dan tidak diasumsikan berdistribusi normal. Apabila uji Friedman signifikan, perbandingan berpasangan dilakukan dengan uji peringkat bertanda Wilcoxon [34], dan nilai $p$ dikoreksi dengan metode Holm [35]. Ukuran efek dilaporkan sebagai $r = Z/\sqrt{N}$, sedangkan interval kepercayaan 95% untuk $R$ dan *Ret* dihitung dengan metode *bootstrap* persentil sebanyak 10.000 pengambilan ulang [36]. Kejadian yang tidak memiliki klaim pada suatu kondisi dihitung sebagai kehilangan kasus pada *Ret* dan dikeluarkan dari perhitungan $U$ agar penghapusan klaim tidak tampak sebagai perbaikan mutu.

Kesesuaian skor gerbang mutu dengan penilaian manusia diukur dengan korelasi peringkat Spearman [37] antara skor AlignScore dan label manusia ordinal (0 = tidak didukung, 1 = didukung sebagian, 2 = didukung) pada tingkat klaim. Perbedaan *precision*@5 antara K2 dan K3 diuji dengan uji Wilcoxon berpasangan pada 30

kueri. Tingkat signifikansi yang digunakan ialah $\alpha = 0{,}05$. Kriteria pertama dan keempat dinyatakan tercapai apabila ambangnya terpenuhi dan nilai $p$ terkoreksi kurang dari 0,05. Kriteria keberhasilan yang ditetapkan sebelum pengujian disajikan pada Tabel 2.

Selain analisis yang ditetapkan sebelum pengujian tersebut, sembilan analisis eksploratif ditambahkan setelah hasil utama diketahui untuk menjelaskan hasil itu: (a) $U$ yang dihitung ulang dengan label setiap penilai sebelum diskusi; (b) sensitivitas $U$ terhadap tiga definisi alternatif, yaitu tanpa klaim "tidak diketahui", hanya bagian yang dimiliki K1 dan K2 (masalah dan tindakan), dan tanpa galat salah peran; (c) taksonomi galat yang dikodekan dari alasan penilai; (d) regresi logistik *generalized estimating equations* (GEE) [38] pada tingkat klaim dengan kejadian sebagai klaster; (e) luas di bawah kurva *receiver operating characteristic* (AUC) untuk AlignScore dan HHEM dengan *bootstrap* berklaster; (f) sapuan $\tau$ dari 0 sampai 0,99 serta penyaring sempurna (*oracle*) yang hanya meloloskan klaim berlabel didukung; (g) efek minimum yang dapat dideteksi pada daya 80%; (h) *bootstrap* Bayes [39] untuk $R$; dan (i) koefisien AC1 Gwet [40] sebagai pelengkap $\kappa$. Hasil analisis eksploratif tidak mengubah keputusan atas keempat kriteria. Nilai $p$ dalam keluarga eksploratif dikoreksi dengan metode Benjamini–Hochberg [41], dan seluruh hasilnya dilaporkan, termasuk yang tidak mendukung dugaan penulis.

**Tabel 2.** Kriteria keberhasilan yang ditetapkan sebelum pengujian

| No. | Kriteria | Ambang | Dasar perhitungan |
|---|---|---|---|
| 1 | Penurunan relatif proporsi klaim tidak didukung, K3 terhadap K2 | $R \geq 50\%$ | Persamaan (3), penilaian manusia |
| 2 | Retensi kasus layak pakai | $Ret \geq 90\%$ | Persamaan (4) |
| 3 | Kesesuaian skor gerbang mutu dengan penilaian manusia | $\rho \geq 0{,}6$ | Korelasi Spearman |
| 4 | Kecocokan penelusuran kasus | $P@5$ K3 > $P@5$ K2 | Persamaan (6), uji Wilcoxon |

### 2.11 Implementasi serta Ketersediaan Kode dan Data

K2 dijalankan dengan Qwen2.5-7B-Instruct [42] terkuantisasi 4-bit secara lokal melalui Ollama pada GPU NVIDIA T4 (Google Colab), dengan *temperature* 0, jendela konteks 8.192 token, dan keluaran paling banyak 1.500 token. Model lokal dipilih agar data operasi tidak perlu dikirim ke layanan pihak ketiga dan agar eksperimen dapat diulang tanpa biaya. Keluaran yang tidak dapat diurai sebagai JSON diminta ulang paling banyak empat kali. Apabila pembangkitan berhenti karena pengulangan token, permintaan diulang dengan *frequency penalty* bertingkat (0,5; 1,0; 1,5); cara cadangan (*fallback*) ini diperlukan pada 10 dari 1.107 kejadian. Seluruh kejadian menghasilkan keluaran yang sah dengan waktu sekitar 13,6 detik per kejadian. Eksperimen dijalankan pada 11 November 2026 menggunakan Python 3.13.16 dengan pustaka rank-bm25, SciPy, dan statsmodels serta implementasi resmi AlignScore dan HHEM-2.1-Open; pengambilan sampel dan *bootstrap* memakai *seed* 2026. Kode program, instruksi model, skema JSON, kamus kata kunci, matriks penilaian, dan label anotasi dipublikasikan di https://github.com/Haikal7090/LLM-IKMS.

## 3. HASIL DAN PEMBAHASAN

### 3.1 Keluaran Model, Kalibrasi Ambang, dan Reliabilitas Penilaian

K2 menghasilkan 7.422 klaim dari 1.107 kejadian, atau rata-rata 6,7 klaim per kejadian, sedangkan K1 menghasilkan 3.067 klaim pada 986 kejadian. Sebanyak 1.873 klaim K2 (25,2%) berisi "*unknown*": 1.082 dari 1.104 klaim penyebab (98,0%) dan 772 dari 1.150 klaim hasil (67,1%). Dengan $\tau = 0{,}94$, gerbang mutu meloloskan 78,6% klaim K2; tingkat lolos terendah terdapat pada pelajaran (59,0%) dan masalah (66,3%).

Pada sampel kalibrasi, $\tau = 0{,}94$ mendeteksi tujuh dari delapan klaim tidak didukung (*recall* 0,88; IK 95% 0,47–1,00) dengan tujuh tanda keliru (presisi 0,50; IK 95% 0,23–0,77). Lebar kedua interval menunjukkan bahwa delapan klaim positif tidak cukup untuk menetapkan ambang secara stabil: pada 1.000 ulangan *bootstrap*, ambang terpilih berkisar dari 0,05 sampai 0,94, dan nilai 0,94 hanya terpilih pada 39,8% ulangan.

Tabel 3 merangkum reliabilitas. Indikator audit P1 memiliki kesepakatan dan ketepatan aturan yang tinggi. Nilai $\kappa$ pada P3 rendah meskipun kesepakatannya 91,0% karena 90% kejadian berjawaban "ya" (paradoks kappa [43]); koefisien AC1, yang lebih tahan terhadap prevalensi ekstrem, bernilai 0,90. P2 paling lemah pada semua koefisien sehingga angka audit yang bersumber dari P2 perlu dibaca dengan hati-hati. Pada penilaian utama, kedua penilai sepakat pada 86,2% baris ($\kappa = 0{,}63$; IK 95% 0,55–0,72), yang tergolong kesepakatan substansial [30], tetapi $\kappa$ turun menjadi 0,41 apabila S dan T dibedakan. Oleh karena itu, hanya pengelompokan biner yang dianalisis. Kesepakatan lebih tinggi pada klaim K1 ($\kappa = 0{,}87$) daripada klaim K2 ($\kappa = 0{,}60$). Kedua penilai juga

berbeda dalam keketatan: Penilai 1 menandai 19,4% baris sebagai tidak didukung, sedangkan Penilai 2 menandai 29,8%. Dari 57 baris yang berbeda secara biner, 53 diputus tidak didukung dalam diskusi.

**Tabel 3.** Reliabilitas antarpenilai sebelum diskusi dan ketepatan indikator audit berbasis aturan terhadap label akhir

| Objek penilaian | *n* | Sepakat (%) | κ | AC1 | Presisi aturan | *Recall* aturan |
|---|---|---|---|---|---|---|
| P1: penyebab tertulis eksplisit | 100 | 95,0 | 0,85 | 0,92 | 0,92 | 1,00 |
| P2: ringkasan harian menyebut jenis masalah | 82 | 70,7 | 0,43 | 0,41 | 0,93 | 0,68 |
| P3: narasi memuat tindakan | 100 | 91,0 | 0,35 | 0,90 | 1,00 | 0,89 |
| Klaim pada penilaian utama (D lawan S atau T) | 413 | 86,2 | 0,63 | 0,78 | – | – |

Catatan: P2 hanya dihitung pada 82 kejadian yang memiliki ringkasan harian menurut kedua penilai.

Audit pada 100 kejadian acak tersebut juga menunjukkan batas atas pengetahuan yang tersedia di sumber. Menurut label akhir, narasi memuat tindakan penanganan pada 90 kejadian, tetapi hanya 23 kejadian yang menyebut penyebab gangguan secara eksplisit, dan ringkasan 24 jam menyebut jenis gangguan pada 40 dari 82 kejadian yang memiliki ringkasan. Dengan kata lain, DDR mencatat apa yang dilakukan jauh lebih lengkap daripada mengapa gangguan terjadi.

### 3.2 Hasil terhadap Kriteria Pra-Spesifikasi

Tidak satu pun dari empat kriteria tercapai (Tabel 4 dan Tabel 5). Proporsi klaim tidak didukung berbeda di antara ketiga kondisi (Friedman $\chi^2 = 22{,}61$; $n = 38$; $p < 0{,}001$). Dua dari 40 kejadian tidak memiliki klaim K1 karena tidak ada kalimatnya yang cocok dengan kata kunci, sehingga uji yang melibatkan K1 memakai 38 kejadian. K2 memuat klaim tidak didukung jauh lebih banyak daripada K1 ($p < 0{,}001$; $r = 0{,}72$), dan K3 tetap lebih buruk daripada K1 ($p = 0{,}007$; $r = 0{,}47$).

**Tabel 4.** Ukuran utama dan sekunder per kondisi

| Kondisi | *n* kejadian | *U* (%) [IK 95%] | Klaim tidak konsisten menurut HHEM (%) | P@5 |
|---|---|---|---|---|
| K1: ekstraksi berbasis aturan | 38 | 13,9 [7,9–21,1] | 0,0 | 0,42 |
| K2: LLM bersitasi | 40 | 37,6 [32,4–43,0] | 30,8 | 0,48 |
| K3: K2 dengan gerbang mutu | 40 | 30,5 [23,4–38,1] | 20,6 | 0,37 |

Catatan: *U* dihitung dari label akhir pada 40 kejadian uji; HHEM dihitung pada semua klaim yang memiliki kalimat rujukan (3.067, 5.465, dan 3.963 klaim); P@5 adalah rerata 30 kueri.

Gerbang mutu menurunkan *U* dari 37,6% menjadi 30,5%, yaitu $R = 18{,}8\%$ (IK 95% 3,7–35,7), tetapi penurunan itu tidak signifikan ($p = 0{,}059$; $r = 0{,}30$) dan jauh di bawah target 50%. Penurunannya juga tidak merata: *U* turun pada 16 kejadian, naik pada 8 kejadian, dan tetap pada 16 kejadian, dengan median selisih nol. Sementara itu, hanya 65,0% dari 246 kasus layak pakai pada data uji masih memuat masalah dan tindakan setelah penyaringan, dan P@5 turun dari 0,48 menjadi 0,37 ($p = 0{,}004$): K3 lebih rendah daripada K2 pada 15 kueri dan lebih tinggi hanya pada satu kueri. Skor AlignScore hampir tidak berkorelasi dengan label penilai ($\rho = 0{,}16$). Akurasi fakta kunci K2 pada 328 kejadian uji adalah 64,6% untuk kategori masalah, 45,1% untuk kegagalan peralatan, dan 85,7% untuk kedalaman.

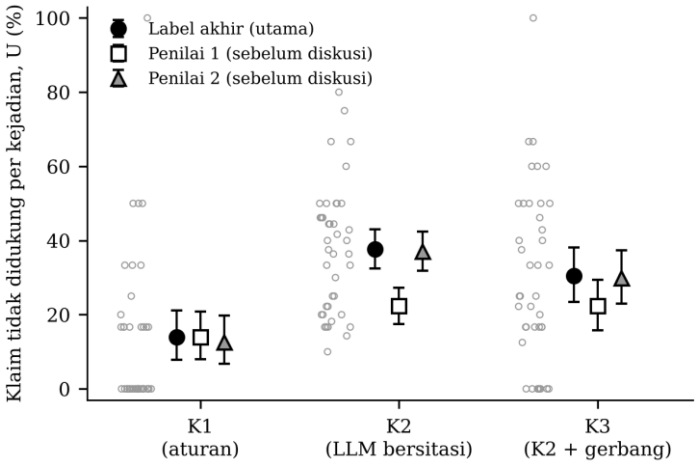
**Tabel 5.** Keputusan atas empat kriteria pra-spesifikasi

| No. | Kriteria | Hasil | Keputusan |
|---|---|---|---|
| 1 | $R \geq 50\%$ dan $p < 0{,}05$ | $R$ = 18,8% (IK 95% 3,7–35,7); $p$ = 0,059 | Tidak tercapai |
| 2 | $Ret \geq 90\%$ | $Ret$ = 65,0% (IK 95% 58,9–70,7); $n$ = 246 | Tidak tercapai |
| 3 | $\rho \geq 0{,}6$ | $\rho$ = 0,16 ($p$ = 0,023; $n$ = 196 klaim) | Tidak tercapai |
| 4 | P@5 K3 > K2 dan $p < 0{,}05$ | 0,37 lawan 0,48; $p$ = 0,004 (arah berlawanan) | Tidak tercapai |

### 3.3 Hasil Analisis Eksploratif

Seluruh hasil pada subbagian ini bersifat eksploratif. Nilai *p* yang dilaporkan sudah dikoreksi dengan metode Benjamini–Hochberg ($p_{BH}$) dalam satu keluarga yang berisi 19 uji.

**Ketahanan terhadap penilai dan definisi.** Arah temuan K2 > K1 bertahan pada label kedua penilai, tetapi besarnya tidak (Gambar 2 dan Tabel 6). Dengan label Penilai 1, *U* K2 hanya 22,3% dan gerbang tidak mengubahnya; dengan label Penilai 2, hasilnya hampir sama dengan label akhir. Pada tingkat klaim, odds klaim K2 untuk dinilai tidak didukung adalah 3,46 kali odds klaim K1 (IK 95% 2,16–5,53; $p_{BH} < 0{,}001$). Rasio odds itu turun menjadi 2,51 (IK 95% 1,35–4,65; $p_{BH} = 0{,}017$) apabila perbandingan dibatasi pada bagian yang dimiliki kedua kondisi, yaitu masalah dan tindakan.




**Gambar 2.** Proporsi klaim tidak didukung per kejadian (*U*) menurut kondisi dan sumber label. Penanda besar menunjukkan rerata dengan IK 95% *bootstrap*; lingkaran kecil menunjukkan nilai setiap kejadian menurut label akhir. Arah K2 > K1 sama pada ketiga sumber label, tetapi selisihnya jauh lebih kecil menurut Penilai 1.

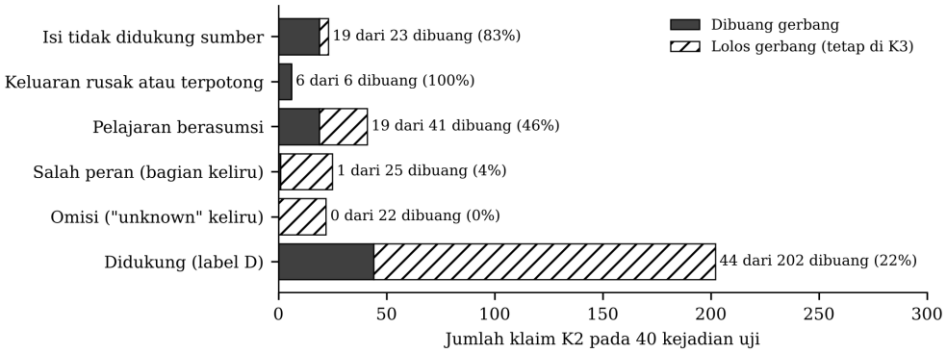
**Tabel 6.** *U* (%) dan reduksi relatif *R* (%) menurut sumber label dan definisi alternatif

| Varian | K1 | K2 | K3 | *p* K1–K2 | *p* K2–K3 | *R* |
|---|---|---|---|---|---|---|
| Label akhir (hasil utama) | 13,9 | 37,6 | 30,5 | < 0,001[a] | 0,059[a] | 18,8 |
| Label Penilai 1 sebelum diskusi | 13,9 | 22,3 | 22,3 | 0,041 | 0,721 | −0,1 |
| Label Penilai 2 sebelum diskusi | 12,6 | 37,0 | 29,9 | < 0,001 | 0,066 | 19,1 |
| Tanpa klaim "*unknown*" | 13,9 | 41,4 | 28,4 | – | 0,018 | 27,1 |
| Hanya bagian masalah dan tindakan | 13,9 | 26,3 | 15,4 | 0,041 | 0,041 | 33,6 |
| Tanpa galat salah peran | 0,0 | 30,0 | 22,3 | < 0,001 | 0,049 | 25,5 |

Catatan: [a] nilai *p* pra-spesifikasi dengan koreksi Holm; nilai lain adalah $p_{BH}$. K1 dan K2 dibandingkan pada 38 kejadian; K2 dan K3 pada 40 kejadian, kecuali pada baris keempat dan kelima (38 kejadian).

Tiga definisi alternatif pada Tabel 6 memperbesar *R* menjadi 25,5–33,6% dan membuat selisih K2–K3 signifikan setelah koreksi. Namun, tidak ada definisi yang mendekatkan *R* ke target 50%, sehingga keputusan atas kriteria 1 tidak bergantung pada definisi *U*.

**Jenis galat.** Alasan penilai memungkinkan 117 klaim K2 yang tidak didukung dikelompokkan menjadi lima jenis (Gambar 3): pelajaran yang berasumsi (41), salah peran (25), isi yang tidak didukung sumber (23), omisi berupa "*unknown*" padahal informasinya tertulis (22), dan keluaran yang rusak atau terpotong (6). Gerbang membuang 25 dari 29 klaim pada dua jenis yang memang menjadi sasaran pencocokan klaim dengan sumber, yaitu isi tidak didukung dan keluaran rusak. Sebaliknya, gerbang hanya membuang 20 dari 88 klaim pada tiga jenis lain dan sekaligus membuang 44 dari 202 klaim yang didukung (21,8%). Semua 22 klaim K1 yang tidak didukung termasuk jenis salah peran. Contoh nyata setiap jenis galat disajikan pada Tabel 7. Tiga klaim terpotong tepat pada ukuran berinci (12 1/4, 8 1/4, dan 3 1/5) karena DDR menulis simbol inci dengan tanda kutip ganda ("), yang tampaknya dibaca model sebagai penutup teks pada format JSON.




**Gambar 3.** Jenis galat pada 319 klaim K2 yang dinilai dan bagian yang dibuang gerbang mutu. Gerbang menangkap hampir semua galat isi dan keluaran rusak, tetapi hampir tidak menangkap galat salah peran dan omisi, yang bersama pelajaran berasumsi mencakup 88 dari 117 galat.

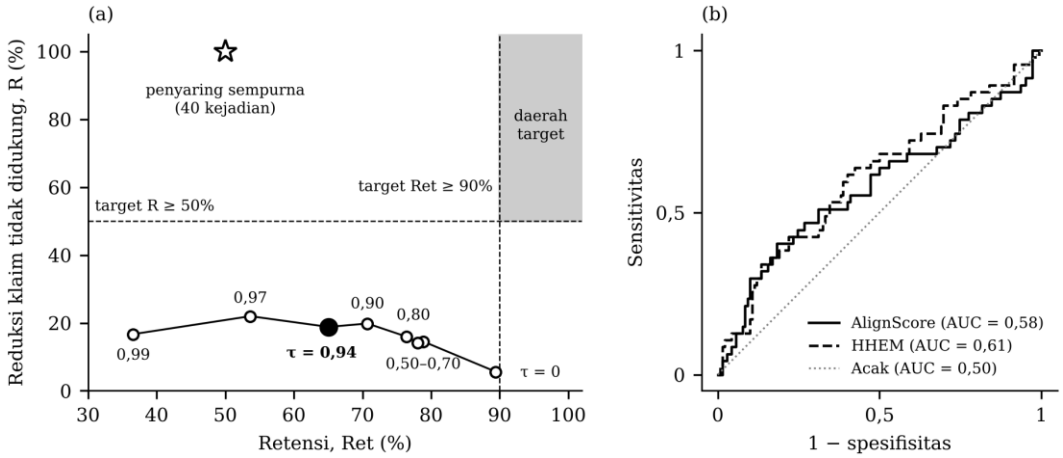
**Tabel 7.** Contoh klaim K2 pada data uji untuk setiap jenis galat beserta kalimat DDR yang dirujuknya

| Jenis galat (dibuang gerbang) | Klaim K2 [bagian] | Kalimat DDR yang dirujuk dan alasan penilai |
|---|---|---|
| Isi tidak didukung (19 dari 23) | *"Racked back 3 1/5"* [tindakan] | *S11: "Was not able to rack back 3 1/5" DP in fingerboard."* Makna dibalik: menurut narasi, DP justru tidak dapat di-*rack back*. |
| Keluaran rusak atau terpotong (6 dari 6) | *"Made up and RIH with 12 1/4"* [tindakan] | *S13: "Made up and RIH with 12 1/4" BHA to 107 m MD."* Klaim berhenti pada tanda inci sehingga objek dan kedalaman hilang. |
| Salah peran (1 dari 25) | *"Tool box talk was held."* [masalah]; *"TDS failure occurred."* [tindakan] | *S1: "Held tool box talk with day shift." S3: "Failure on TDS."* Peran tertukar: rapat keselamatan rutin dicatat sebagai masalah, sedangkan kerusakan top drive dicatat sebagai tindakan. |
| Omisi "*unknown*" (0 dari 22) | *"unknown"* [penyebab] | *S1: "Stopped skidding due to burst hose on skid cylinder."* Penyebab tertulis eksplisit dengan penanda *due to*. |
| Pelajaran berasumsi (19 dari 41) | *"Regularly inspect BOP components to prevent unexpected failures during critical operations."* [pelajaran] | *S8: "Unable to achieve pressure test of cement unit." S13: "Troubleshot leak on cement unit."* Gangguan terjadi pada *cement unit*; narasi tidak mencatat gangguan pada BOP, yang hanya diinspeksi dan diuji. |

Catatan: semua contoh berlabel akhir tidak didukung. Angka dalam kurung adalah jumlah klaim jenis tersebut yang dibuang gerbang mutu (Gambar 3). Kutipan DDR ditulis apa adanya, termasuk tanda kutip ganda sebagai simbol inci.

**Skor otomatis.** Untuk membedakan klaim fakta yang didukung dari yang tidak didukung menurut penilai ($n$ = 189; 47 tidak didukung), AUC AlignScore adalah 0,58 (IK 95% 0,45–0,70) dan AUC HHEM 0,61 (IK 95% 0,49–0,72). Selisih keduanya tidak bermakna (0,03; IK 95% −0,09 sampai 0,14; $p_{BH}$ = 0,642), sehingga dugaan awal penulis bahwa HHEM lebih selaras dengan penilai tidak terbukti (Gambar 4b). Apabila yang dihitung sebagai positif hanya galat isi dan keluaran rusak (22 klaim), AUC naik menjadi 0,84 untuk AlignScore dan 0,78 untuk HHEM.

**Ambang dan batas atas.** Sapuan τ menunjukkan bahwa kegagalan tidak disebabkan oleh nilai ambang yang dipilih (Gambar 4a). Pada rentang τ = 0 sampai 0,99, $R$ hanya bergerak antara 5,6% dan 22,0%, sedangkan *Ret* turun dari 89,4% menjadi 36,6%. Bahkan cek leksikal tanpa AlignScore (τ = 0) tidak memenuhi kriteria retensi. Penyaring sempurna, yang hanya meloloskan klaim berlabel D, akan mempertahankan masalah dan tindakan pada 50,0% dari 40 kejadian yang dinilai. Analisis sensitivitas daya menunjukkan bahwa rancangan dengan 40 pasangan mampu mendeteksi selisih sebesar 9,3 poin persentase (setara dengan $R \approx 25\%$) pada daya 80%, sehingga $R$ sebesar target 50% semestinya terdeteksi apabila ada. *Bootstrap* Bayes memberi peluang 0,997 bahwa $R > 0$ dan peluang kurang dari 0,001 bahwa $R \geq 50\%$.




**Gambar 4.** (a) Reduksi klaim tidak didukung ($R$) dan retensi (*Ret*) pada berbagai nilai τ; lingkaran hitam adalah τ = 0,94 yang dipakai, dan bintang adalah penyaring sempurna yang dihitung pada 40 kejadian berlabel. Tidak ada nilai τ yang memasuki daerah target; (b) kurva ROC AlignScore dan HHEM untuk mendeteksi klaim fakta K2 yang tidak didukung menurut penilai.

**Beban verifikasi.** Tidak ada satu pun dari 40 laporan K2 yang bebas dari klaim tidak didukung; rata-rata 2,9 dari 8,0 klaim per laporan bermasalah. Setelah penyaringan, 8 dari 40 laporan (20%) bersih.

### 3.4 Pembahasan

**Sitasi bukan jaminan dukungan.** Setiap klaim fakta K2 mencantumkan nomor kalimat sumber, tetapi sekitar sepertiganya dinilai tidak didukung menurut label akhir. Temuan ini sejalan dengan kajian atribusi pada sistem generatif, yang melaporkan bahwa keberadaan sitasi tidak menjamin dukungan sumber [17], [22]. Proporsi klaim K2 yang didukung penuh (62,4%) berada pada orde yang sama dengan 51,5% kalimat yang didukung penuh oleh sitasinya pada mesin pencari generatif populer [17]. Besaran pastinya perlu dibaca dengan hati-hati karena bergantung pada keketatan penilai (22,3% sampai 37,0%). Meskipun demikian, arahnya konsisten pada kedua penilai dan bertahan ketika perbandingan dibatasi pada bagian yang setara. Bagi pembaca, laporan yang rapi dan bersitasi justru menyulitkan: tidak ada laporan yang seluruh klaimnya dapat dipercaya tanpa diperiksa, dan sitasi tidak menunjukkan klaim mana yang keliru. Gejala inilah yang disebut *workslop* [18], [19], yaitu keluaran yang tampak selesai tetapi memindahkan pekerjaan kepada penerimanya.

**Mengapa gerbang gagal.** Kegagalan gerbang lebih disebabkan oleh ketidakcocokan antara rancangan gerbang dan jenis galat daripada oleh kelemahan pencocokan itu sendiri. Pencocokan klaim dengan sumber hanya dapat menjawab satu pertanyaan, yaitu apakah isi klaim tertulis pada kalimat rujukannya. Hanya 29 dari 117 galat K2 (24,8%) termasuk jenis itu, dan gerbang menangkap sebagian besar di antaranya. Tiga jenis lain berada di luar jangkauannya. Klaim salah peran lolos karena isinya memang tertulis di sumber, seperti rapat keselamatan rutin yang dicatat sebagai masalah (Tabel 7). Omisi lolos karena tidak ada pernyataan yang dapat diperiksa; model menulis penyebab "*unknown*" pada 98,0% kejadian, padahal pada sampel uji 14 dari 38 klaim itu keliru karena penyebabnya tertulis di narasi. Pelajaran yang berasumsi hanya tertangkap secara tidak langsung, yaitu ketika fakta yang dirujuknya ikut dibuang. Pola ini menjelaskan mengapa perubahan τ tidak menolong dan mengapa skor otomatis tampak lemah terhadap label penilai secara keseluruhan, tetapi cukup baik untuk galat isi.

**Batas pada pembangkit.** Karena gerbang hanya dapat membuang, mutu K3 dibatasi oleh mutu K2. Penyaring sempurna pun hanya menyisakan laporan yang utuh pada separuh kejadian, sehingga kriteria reduksi

dan kriteria retensi tidak dapat dipenuhi bersama dengan pembangkit ini. Perbaikan yang menjanjikan dengan demikian berada di hulu, yaitu pada model dan instruksinya, atau pada rancangan yang memperbaiki klaim dan bukan sekadar membuangnya.

**Batas pada sumber.** Audit pada Subbagian 3.1 menunjukkan batas yang lebih hulu lagi. Hanya 23 dari 100 narasi NPT menyebut penyebab secara eksplisit, padahal pelajaran pencegahan bertumpu pada penyebab. Akibatnya, pembangkit dihadapkan pada dua pilihan yang sama-sama merugikan: menulis "*unknown*" dan kehilangan pelajaran, atau menyimpulkan penyebab sendiri dan menghasilkan pelajaran berasumsi. Model pada penelitian ini menempuh keduanya sekaligus, yaitu menulis "*unknown*" pada 98,0% klaim penyebab, tetapi tetap menulis pelajaran yang mengandaikan penyebab atau kejadian yang tidak tertulis, seperti anjuran inspeksi BOP pada kejadian yang gangguannya terjadi pada *cement unit* (Tabel 7). Bagi manajemen pengetahuan, mutu basis kasus dengan demikian sudah dibatasi sejak DDR ditulis. Kolom penyebab yang terstruktur pada DDR, misalnya dengan status dugaan atau terkonfirmasi, berpeluang menaikkan batas atas tersebut, baik bagi penelusuran manual maupun bagi LLM.

**Metrik otomatis dan penilaian insinyur.** HHEM menunjukkan penurunan klaim tidak konsisten dari 30,8% menjadi 20,6% setelah penyaringan, lebih besar daripada penurunan menurut penilai. Evaluasi yang hanya mengandalkan metrik otomatis akan menyimpulkan bahwa gerbang cukup berhasil. Selisih itu muncul karena metrik otomatis mengukur konstruk yang lebih sempit daripada mutu menurut insinyur, yang juga mencakup kelengkapan dan ketepatan peran informasi.

**Dampak pada penelusuran kasus.** Penurunan P@5 konsisten dengan temuan bahwa gerbang membuang seperlima klaim yang didukung dan sepertiga laporan kehilangan masalah atau tindakan. Kosakata yang hilang mengurangi peluang laporan ditemukan oleh kueri sejenis. Selisih P@5 antara K1 dan K2 tidak signifikan sehingga penelitian ini tidak menyimpulkan bahwa LLM lebih unggul untuk pencarian.

### 3.5 Implikasi bagi Manajemen Pengetahuan Pengeboran

Pertama, repositori *lessons learned* yang diisi LLM tanpa tinjauan akan memuat klaim keliru pada hampir setiap entri, dan pelajaran merupakan bagian yang paling sering bermasalah (41 dari 61 pelajaran yang dinilai). Pelajaran yang keliru berisiko mengarahkan tindakan pencegahan ke penyebab yang salah. Kedua, protokol pada penelitian ini dapat dipakai sebagai uji terima sebelum sebuah sistem dipasang: kriteria ditetapkan lebih dahulu, klaim dinilai satu per satu oleh dua penilai, dan kegunaan diukur bersama ketepatan. Logikanya serupa dengan uji integritas formasi (*formation integrity test*) di bawah sepatu selubung sebelum trayek berikutnya dibor [44]: tekanan uji ditetapkan sebelum pengujian, dan uji yang tidak lulus menjadi alasan untuk memperbaiki sebelum melanjutkan, bukan tanda bahwa ujinya gagal. Dalam kerangka itu, hasil nol dari empat kriteria adalah keluaran sah dari uji terima, yaitu bahwa sistem ini belum layak mengisi basis kasus tanpa tinjauan ahli. Ketiga, klaim keberhasilan yang hanya bersandar pada metrik otomatis perlu divalidasi dengan penilaian manusia pada data operasi sendiri. Keempat, hasil ini menyarankan pembagian peran yang lebih aman: ekstraksi berbasis aturan untuk mengutip fakta, LLM sebagai draf yang diberi tanda belum diverifikasi, pemeriksaan khusus untuk peran klaim dan untuk jawaban "*unknown*", serta tinjauan ahli sebelum entri dipublikasikan. Kelima, sebagian perbaikan dapat dilakukan di hulu, yaitu kolom penyebab yang terstruktur pada templat DDR dan normalisasi notasi, seperti tanda inci, sebelum teks diproses LLM. Seluruh protokol dapat diulang dengan biaya rendah karena memakai model lokal dan data publik.

### 3.6 Ancaman terhadap Validitas dan Keterbatasan

*Validitas internal.* Penilai adalah penulis yang berstatus mahasiswa. Meskipun label kondisi disembunyikan dan penilai tidak terlibat dalam penyusunan sistem, kalimat K1 yang disalin apa adanya masih dapat dikenali dari gayanya. Label akhir bergantung pada diskusi yang hampir selalu berakhir pada label yang lebih ketat, sesuai dengan aturan matriks untuk kasus ragu; karena itu hasil per penilai dilaporkan berdampingan. Ambang dikalibrasi dari sampel yang hanya memuat delapan klaim tidak didukung.

*Validitas konstruk.* Label T mencakup klaim yang tidak didukung dan klaim yang salah peran, dan $\kappa$ untuk tiga kategori rendah. Pada 23 baris, satu label "*unknown*" dipakai sekaligus untuk klaim penyebab dan klaim hasil karena teksnya sama. Taksonomi galat dikodekan dengan aturan kata kunci atas alasan penilai dan diperiksa penulis, bukan oleh pengode independen, sehingga batas antarjenis tidak selalu tegas. Relevansi pada P@5 hanya didasarkan pada kesamaan kode masalah.

*Validitas eksternal.* Penelitian ini memakai satu lapangan, satu model 7 miliar parameter yang terkuantisasi, satu versi instruksi model, dan satu rancangan gerbang. Hasilnya tidak dapat digeneralisasi ke model yang lebih besar, ke DDR berbahasa Indonesia, ataupun ke rancangan gerbang lain.

*Validitas kesimpulan statistik.* Sampel 40 kejadian membatasi daya uji untuk efek kecil; selisih K2–K3 dilaporkan sebagai tidak signifikan dan tidak ditafsirkan sebagai bukti adanya ataupun tidak adanya efek di bawah 9,3 poin persentase. Analisis eksploratif dirancang setelah hasil diketahui sehingga perlu dikonfirmasi pada data baru.

## 4. KESIMPULAN

Penelitian ini menguji penyaringan klaim berbasis sumber untuk *lessons learned* NPT hasil LLM dengan empat kriteria yang ditetapkan sebelum pengujian, dan tidak satu pun kriteria tercapai. Untuk pertanyaan pertama, LLM dengan sitasi wajib menghasilkan klaim tidak didukung jauh lebih sering daripada ekstraksi berbasis aturan (37,6% lawan 13,9%). Arah temuan ini sama pada kedua penilai, tetapi besarnya bergantung pada keketatan penilai, dan tidak ada laporan LLM yang bebas dari klaim tidak didukung. Untuk pertanyaan kedua, gerbang mutu hanya menurunkan proporsi klaim tidak didukung sebesar 18,8% secara tidak signifikan dan hanya mempertahankan 65,0% kasus layak pakai, sedangkan skor AlignScore hampir tidak sejalan dengan label penilai ($\rho = 0{,}16$). Untuk pertanyaan ketiga, penyaringan tidak meningkatkan kecocokan penelusuran kasus; P@5 justru turun dari 0,48 menjadi 0,37.

Analisis eksploratif menunjukkan sebabnya. Gerbang mutu menangkap sebagian besar galat isi, tetapi tiga perempat galat berupa salah peran, omisi, dan pelajaran berasumsi, yang berada di luar jangkauan pencocokan klaim dengan sumber. Karena gerbang mutu hanya dapat membuang, mutunya dibatasi oleh mutu pembangkit, sedangkan batas yang lebih hulu terdapat pada DDR itu sendiri, yang hanya menyebut penyebab secara eksplisit pada 23 dari 100 kejadian. Dengan demikian, kontribusi utama penelitian ini adalah protokol evaluasi dan diagnosis tersebut, bukan gerbang mutunya. Bagi praktik manajemen pengetahuan pengeboran, sitasi dan metrik otomatis belum dapat menggantikan tinjauan ahli, dan sistem berbasis LLM perlu melewati uji terima dengan penilaian manusia sebelum dipakai untuk mengisi basis kasus. Seperti uji integritas formasi sebelum trayek berikutnya dibor, uji terima yang tidak lulus bukanlah akhir pekerjaan, melainkan informasi yang mencegah pengetahuan yang belum layak masuk ke basis kasus.

Penelitian lanjutan perlu mengonfirmasi temuan eksploratif pada data baru dengan penilai ahli yang independen dan sampel yang lebih besar, menguji model yang lebih besar, menambahkan pemeriksaan peran klaim dan jawaban "tidak diketahui", menguji apakah kolom penyebab terstruktur pada DDR menaikkan batas atas pengetahuan, serta merancang gerbang mutu yang memperbaiki klaim dan tidak hanya membuangnya.

**PERNYATAAN**

Data Volve digunakan sesuai dengan Equinor Open Data Licence [28]. Penulis menggunakan asisten kecerdasan artifisial generatif (Claude, Anthropic) untuk membantu menyusun kode analisis dan draf naskah serta merapikan penulisan; seluruh data, analisis, dan kesimpulan diperiksa oleh penulis dan menjadi tanggung jawab penulis.

## 5. DAFTAR PUSTAKA


[1] Antara, "Realisasi produksi minyak, kondensat, dan NGL tercatat 576,2 MBOPD," *Antara News*, Jun. 3, 2026. [Online]. Available: https://www.antaranews.com/berita/5592216/realisasi-produksi-minyak-kondensat-dan-ngl-tercatat-5762-mbopd

[2] Investortrust.id, "PHE siapkan 16 sumur eksplorasi dan 800 sumur produksi pada 2026," Mar. 10, 2026. [Online]. Available: https://investortrust.id/business/96767/phe-siapkan-16-sumur-eksplorasi-dan-800-sumur-produksi-pada-2026

[3] P. E. Sorensen, P. E. J. Andresen, and J. F. Odgaard, "Maersk looks beyond traditional rig downtime scope, adopts data-based approach to reduce operator NPT," *Drilling Contractor*, Jun. 26, 2018. [Online]. Available: https://drillingcontractor.org/maersk-looks-beyond-traditional-rig-downtime-scope-adopts-data-based-approach-to-reduce-operator-npt-47432

[4] M. Ariyon, B. Rahman, E. Sastraningsih, and A. Mayes, "The mitigation of risk management: Non-productive time analysis on drilling operations in ZY field," *J. Geosci. Eng. Environ. Technol.*, vol. 9, no. 2, pp. 174–179, 2024, doi: 10.25299/jgeet.2024.9.2.15261.

[5] R. Weber, D. W. Aha, and I. Becerra-Fernandez, "Intelligent lessons learned systems," *Expert Syst. Appl.*, vol. 20, no. 1, pp. 17–34, 2001.

[6] A. Aamodt and E. Plaza, "Case-based reasoning: Foundational issues, methodological variations, and system approaches," *AI Commun.*, vol. 7, no. 1, pp. 39–59, 1994.

[7] S. V. Shokouhi, P. Skalle, and A. Aamodt, "An overview of case-based reasoning applications in drilling engineering," *Artif. Intell. Rev.*, vol. 41, pp. 317–329, 2014, doi: 10.1007/s10462-011-9310-2.

[8] O. E. Gundersen, F. Sørmo, A. Aamodt, and P. Skalle, "A real-time decision support system for high cost oil-well drilling operations," in *Proc. AAAI Conf. Artif. Intell.*, vol. 26, no. 2, 2012, pp. 2209–2216, doi: 10.1609/aaai.v26i2.18959.

[9] H. J. Duhon and J. S. Elias, "Why it is difficult to learn lessons: Insights from decision theory and cognitive science," *SPE Proj. Facil. Constr.*, vol. 3, no. 3, Sep. 2008, Paper SPE-110211.

[10] J. Hoffimann, Y. Mao, A. Wesley, and A. Taylor, "Sequence mining and pattern analysis in drilling reports with deep natural language processing," 2017, *arXiv:1712.01476*.

[11] H. Liu *et al.*, "Research status and application of artificial intelligence large models in the oil and gas industry," *Pet. Explor. Dev.*, vol. 51, no. 4, pp. 1049–1065, 2024.

[12] P. S. Rathore, S. Verma, G. Nair, and A. Srivastava, "Application of large language models for analysis of textual data from the oil & gas industry," in *Fifth EAGE Digitalization Conf. Exhib.*, Edinburgh, U.K., 2025, doi: 10.3997/2214-4609.202539053.

[13] R. Lu, "TADI: Tool-augmented drilling intelligence via agentic LLM orchestration over heterogeneous wellsite data," 2026, *arXiv:2605.00060*.
[14] Z. Ji *et al.*, "Survey of hallucination in natural language generation," *ACM Comput. Surv.*, vol. 55, no. 12, Art. no. 248, 2023, doi: 10.1145/3571730.
[15] L. Huang *et al.*, "A survey on hallucination in large language models: Principles, taxonomy, challenges, and open questions," *ACM Trans. Inf. Syst.*, 2024, doi: 10.1145/3703155.
[16] Vectara, "Hallucination leaderboard," GitHub, 2026. Accessed: Oct. 30, 2026. [Online]. Available: https://github.com/vectara/hallucination-leaderboard
[17] N. Liu, T. Zhang, and P. Liang, "Evaluating verifiability in generative search engines," in *Findings Assoc. Comput. Linguist.: EMNLP 2023*, Singapore, 2023, pp. 7001–7025, doi: 10.18653/v1/2023.findings-emnlp.467.
[18] K. Niederhoffer, G. Rosen Kellerman, A. Lee, A. Liebscher, K. Rapuano, and J. T. Hancock, "AI-generated 'workslop' is destroying productivity," *Harvard Bus. Rev.*, Sep. 22, 2025. [Online]. Available: https://hbr.org/2025/09/ai-generated-workslop-is-destroying-productivity
[19] A. Liebscher, A. Y. Lee, K. Rapuano, G. Kellerman, K. Niederhoffer, and J. Hancock, "Workslop: Examining the prevalence, antecedents and consequences of low-quality AI-generated content at work," PsyArXiv, 2026. [Online]. Available: https://osf.io/preprints/psyarxiv/5f78h_v1
[20] F. Dell'Acqua *et al.*, "Navigating the jagged technological frontier: Field experimental evidence of the effects of artificial intelligence on knowledge worker productivity and quality," Harvard Business School, Boston, MA, USA, Working Paper 24-013, 2023, doi: 10.2139/ssrn.4573321.
[21] W. M. Olatokun and B. D. Oladokun, "Hallucination in generative AI: Challenges to data integrity, ethical concerns and implications for knowledge management," *Inf. Serv. Use*, 2026, doi: 10.1177/18758789261463098.
[22] T. Gao, H. Yen, J. Yu, and D. Chen, "Enabling large language models to generate text with citations," in *Proc. Conf. Empirical Methods Natural Lang. Process.*, Singapore, 2023, pp. 6465–6488, doi: 10.18653/v1/2023.emnlp-main.398.
[23] S. Min *et al.*, "FActScore: Fine-grained atomic evaluation of factual precision in long form text generation," in *Proc. Conf. Empirical Methods Natural Lang. Process.*, Singapore, 2023, pp. 12076–12100, doi: 10.18653/v1/2023.emnlp-main.741.
[24] H. Rashkin *et al.*, "Measuring attribution in natural language generation models," *Comput. Linguist.*, vol. 49, no. 4, pp. 777–840, 2023, doi: 10.1162/coli_a_00486.
[25] Y. Zha, Y. Yang, R. Li, and Z. Hu, "AlignScore: Evaluating factual consistency with a unified alignment function," in *Proc. 61st Annu. Meeting Assoc. Comput. Linguist. (Vol. 1: Long Papers)*, Toronto, Canada, 2023, pp. 11328–11348, doi: 10.18653/v1/2023.acl-long.634.
[26] O. Mendelevitch, F. Bao, M. Li, and R. Luo, "HHEM 2.1: A better hallucination detection model and a new leaderboard," Vectara, Aug. 5, 2024. [Online]. Available: https://www.vectara.com/blog/hhem-2-1-a-better-hallucination-detection-model/
[27] L. Tang *et al.*, "Understanding factual errors in summarization: Errors, summarizers, datasets, error detectors," in *Proc. 61st Annu. Meeting Assoc. Comput. Linguist. (Vol. 1: Long Papers)*, Toronto, Canada, 2023, pp. 11626–11644, doi: 10.18653/v1/2023.acl-long.650.
[28] Equinor, "Volve field data set," 2018. [Online]. Available: https://www.equinor.com/energy/volve-data-sharing
[29] J. Cohen, "A coefficient of agreement for nominal scales," *Educ. Psychol. Meas.*, vol. 20, no. 1, pp. 37–46, 1960, doi: 10.1177/001316446002000104.
[30] J. R. Landis and G. G. Koch, "The measurement of observer agreement for categorical data," *Biometrics*, vol. 33, no. 1, pp. 159–174, 1977, doi: 10.2307/2529310.
[31] S. Robertson and H. Zaragoza, "The probabilistic relevance framework: BM25 and beyond," *Found. Trends Inf. Retr.*, vol. 3, no. 4, pp. 333–389, 2009, doi: 10.1561/1500000019.
[32] C. D. Manning, P. Raghavan, and H. Schütze, *Introduction to Information Retrieval*. Cambridge, U.K.: Cambridge Univ. Press, 2008.
[33] M. Friedman, "The use of ranks to avoid the assumption of normality implicit in the analysis of variance," *J. Amer. Statist. Assoc.*, vol. 32, no. 200, pp. 675–701, 1937, doi: 10.1080/01621459.1937.10503522.
[34] F. Wilcoxon, "Individual comparisons by ranking methods," *Biometrics Bull.*, vol. 1, no. 6, pp. 80–83, 1945, doi: 10.2307/3001968.
[35] S. Holm, "A simple sequentially rejective multiple test procedure," *Scand. J. Statist.*, vol. 6, no. 2, pp. 65–70, 1979.
[36] B. Efron and R. J. Tibshirani, *An Introduction to the Bootstrap*. New York, NY, USA: Chapman & Hall, 1993.
[37] C. Spearman, "The proof and measurement of association between two things," *Amer. J. Psychol.*, vol. 15, no. 1, pp. 72–101, 1904, doi: 10.2307/1412159.
[38] K.-Y. Liang and S. L. Zeger, "Longitudinal data analysis using generalized linear models," *Biometrika*, vol. 73, no. 1, pp. 13–22, 1986, doi: 10.1093/biomet/73.1.13.

[39] D. B. Rubin, “The Bayesian bootstrap,” *Ann. Statist.*, vol. 9, no. 1, pp. 130–134, 1981, doi: 10.1214/aos/1176345338.
[40] K. L. Gwet, “Computing inter-rater reliability and its variance in the presence of high agreement,” *Brit. J. Math. Statist. Psychol.*, vol. 61, no. 1, pp. 29–48, 2008, doi: 10.1348/000711006X126600.
[41] Y. Benjamini and Y. Hochberg, “Controlling the false discovery rate: A practical and powerful approach to multiple testing,” *J. Roy. Statist. Soc. B*, vol. 57, no. 1, pp. 289–300, 1995, doi: 10.1111/j.2517-6161.1995.tb02031.x.
[42] Qwen Team, “Qwen2.5 technical report,” 2024, *arXiv:2412.15115*.
[43] A. R. Feinstein and D. V. Cicchetti, “High agreement but low kappa: I. The problems of two paradoxes,” *J. Clin. Epidemiol.*, vol. 43, no. 6, pp. 543–549, 1990, doi: 10.1016/0895-4356(90)90158-L.
[44] A. T. Bourgoyne Jr., K. K. Millheim, M. E. Chenevert, and F. S. Young Jr., *Applied Drilling Engineering*, SPE Textbook Series, vol. 2. Richardson, TX, USA: Society of Petroleum Engineers, 1986.

## LAMPIRAN

Dokumentasi berikut memperlihatkan pelaksanaan penilaian klaim. Kedua penilai Tim B menilai lembar penilaian utama secara terpisah tanpa akses ke kunci kondisi, sedangkan Tim A memegang kunci kondisi dan menjalankan pengolahan data.



**Gambar L1.** Penilai pertama (Tim B) melakukan anotasi label klaim.



**Gambar L2.** Penilai kedua (Tim B) melakukan anotasi label klaim.



**Gambar L3.** Tim A, penyusun sistem dan pemegang kunci kondisi, memeriksa lembar kerja keluaran eksperimen.